


A 股多因子选股策略研究报告

摘要

本报告说明一个以可复现研究流程为目标的 A 股多因子选股框架。当前版本使用项目内合成样例数据验证完整链路，覆盖数据读取、数据清洗、因子构建、因子预处理、IC 检验、分组收益、组合构建、事件式回测、风险暴露和 LLM 事件标签示例。报告中的收益、夏普、回撤、换手等结果只用于检查工程流程是否连通，不代表真实市场可获得收益，也不构成投资建议。

项目的核心产物位于 reports/figures/: performance_metrics.csv 保存绩效指标，ic_summary.csv 保存因子 IC 摘要，group_returns.csv 保存分组收益，factor_corr.csv 保存因子相关性，sample_nav.csv、sample_orders.csv、sample_fills.csv、sample_positions.csv 分别保存净值、订单、成交和持仓。PNG 图表与 CSV 同源生成，便于复核图表背后的数据。



数据来源与处理

当前数据由 ashare_factor_research.data.sample_data 生成，包含日行情、日估值基础指标、行业分类、财务指标和新闻事件标签。日行情粒度为 trade_date + ts_code，字段包括开高低收、成交量、成交额、复权因子、停牌标记、ST 标记和涨跌停价。估值基础表同样以 trade_date + ts_code 为主键，包含 PE、PB、总市值、换手率和资金流字段。财务指标表以报告期、公告日、可用日和股票代码描述 point-in-time 可用性。新闻事件表以发布时间和股票代码描述事件类型、情绪、影响周期、置信度和原因。

数据处理遵循以下原则。第一，日期字段统一转换为时间类型，并明确交易日和自然日的区别。第二，日频面板默认以 trade_date + ts_code 作为主键检查重复记录。第三，价格相关计算基于复权收盘价，

避免把除权除息造成的价格跳变误当作收益。第四，财务数据必须通过 `usable_date` 控制可用时间，原则上只能在公告后下一交易日使用。第五，股票池过滤会剔除停牌、ST 和明显不可交易样本，但当前合成数据不能覆盖退市、长期停牌、真实涨跌停成交限制和历史指数成分变化。

数据风险需要单独说明。当前样例并没有真实指数成分历史、退市股票、真实公告修订历史、真实停牌和真实涨跌停撮合数据，因此无法证明不存在生存者偏差，也无法验证所有交易在真实市场中可成交。真实数据版本应保存数据来源、拉取时间、字段映射、复权口径和样本空间定义，并在报告中记录数据版本。若只保留当前仍上市股票，或使用未来才能知道的指数成分、行业分类、ST 状态、财务修订值，都可能显著抬高回测表现。

因子构建

项目当前实现的因子分为四类。量价因子包括 20 日动量、跳过近 5 日的 60 日动量、5 日反转、20 日波动率、20 日平均换手率和 Amihud 非流动性近似值。基本面因子包括市值、账面市值比、盈利收益率、ROE、毛利率、收入同比和利润同比。资金流因子使用日基础表中的净资金流字段构造 20 日资金流强度。LLM 事件因子使用事件情绪和置信度构造 20 日事件情绪得分。

因子定义必须绑定时间语义。报告采用的默认假设是：因子在信号日 `trade_date` 收盘后计算，组合在下一交易日生效，因子检验目标为未来 20 个交易日收益。这个假设避免了同日收盘信号同日成交的明显未来函数，但仍未完全解决真实开盘成交、集合竞价滑点、涨跌停不可买卖、停牌复牌、调仓延迟和订单冲击问题。真实版本应把信号日、执行日、持有期结束日和收益计算窗口写入每个输出文件的元数据。

Notebook 03_factor_construction.ipynb 会输出 `reports/notebook_outputs/factor_coverage.csv`，pipeline 还会输出按日期、行业和市值分桶的覆盖率审计。覆盖率是解释结果前必须检查的内容。如果某些因子只覆盖少数股票或少数日期，IC 和分组收益可能主要反映样本选择，而不是因子有效性。基本面因子还需要关注公告集中期造成的覆盖断点，资金流和换手类因子需要关注零成交和停牌记录，LLM 事件因子需要关注事件覆盖是否集中在少数行业或少数股票。

因子预处理

因子预处理由 `factor_processor` 完成，当前包括 MAD 去极值、截面 z-score 标准化，以及可选的行业和市值中性化。预处理必须在每个交易日的横截面内完成，不能跨日期使用未来样本。中性化只应使用信号日已知的行业和市值字段，不能使用未来行业调整或未来市值。若真实研究中引入更多风格因子，例如

Beta、波动率、流动性、估值和成长暴露，应明确残差化的自变量、截面样本、缺失处理和回归权重。

组合交易 score 采用严格滞后的 walk-forward 流程：训练窗口确定方向和候选因子，验证窗口检查方向一致性，下一调仓月固定权重测试。样本历史不足时，sample 模式可降级为简单均值以验证工程链路；real 模式若不能形成样本外 score 则直接失败。全样本 IC 只用于诊断展示，不参与同期交易权重。


因子有效性检验

因子检验包括 Rank IC、ICIR、命中率、t 值、分组收益、多空组差和因子相关性。检验结论应关注稳定性，而不是只看均值。一个因子如果平均 IC 为正，但主要由少数极端日期贡献，或只在某个行业、某个市值区间、某个短样本期有效，就不能直接作为稳健信号。当前输出了

ic_summary.csv、ic_series.csv、group_returns.csv 和


factor_corr.csv，后续真实数据版本应继续增加分年度 IC、滚动 IC、分市场状态 IC、因子衰减、覆盖率分组、行业中性前后对比和成本敏感性。

Sample score Rank IC series



分组收益用于检查因子排序是否具有单调性。当前 group_return.png 展示的是 score 的 Q5-Q1 累计差值。若真实数据中分组曲线不单调，或者多空收益来自空头端而 A 股实际难以做空，则不能简单把多空收益解释为可交易收益。对于只能做多的组合，更应关注 Top 组相对基准的超额、换手和回撤，而不是理论多空价差。

Sample grouped long-short return




多因子组合构建

组合构建使用月末调仓日期，默认按配置选择 Top50、单票上限 5%，并设置最小持仓数和单行业上限。当候选数量或约束组合不可行时，组合构建函数会抛出错误，而不是静默放松约束。

当前组合已支持单行业上限、最小持仓数、最大换手、最小成交额和成交额参与率；主动行业偏离作为归因结果输出。相对基准的逐股优化和更细现金目标仍属于后续真实组合优化范围。事件式回测输出订单、成交和持仓，并考虑下一交易日开盘执行、手数、涨跌停、停牌、资金不足和持仓延续，但样例数据仍不能代表真实盘口和成交深度。

回测结果

回测由 `run_event_backtest` 完成。信号日期为 `T`，目标权重从下一交易日开始生成订单并按开盘价尝试成交。净值使用收盘价盯市，成本模型包含佣金、印花税、滑点和冲击成本的基础扣减。`sample_orders.csv` 记录请求数量、成交数量、目标权重、当前权重和未成交原因；`sample_fills.csv` 记录成交价格、数量、名义金额和成本拆分；`sample_positions.csv` 记录每日持仓市值和权重。相比只输出净值的回测，这些表更容易审计交易是否真的发生。




绩效指标以 `performance_metrics.csv` 为准，年化默认使用 252 个交易日。由于样本长度较短且数据为合成数据，年化收益、夏普和 Calmar 对样本路径非常敏感。报告不应把该结果宣传为策略真实收益，而应作为流水线是否能计算、保存、复现和展示指标的验证。

样例 bundle 含合成基准，只用于验证严格日期对齐和相对指标计算；真实模式必须使用与股票池匹配的真实基准，日期不一致时不做隐式填充。若基准不匹配，例如用大盘指数评价小盘股票池，超额表现可能主要来自风格暴露而不是选股能力。

风险归因与稳健性检验

当前风险输出包括净值回撤、回撤区间、月度收益热力图、年度收益、换手率、成本归因和行业暴露。行业暴露由组合权重与信号日行业分类聚合得到，用于观察组合是否集中在少数行业。样例中行业分类是按股票顺序合成生成的，不能用于真实行业风险判断。真实版本应接入申万或中信行业分类，并检查行业暴露是否在调仓日后发生显著漂移。

Sample latest industry exposure



稳健性模块已覆盖滚动样本外窗口、零/标准/高成本、延迟 1/2/3 日和成交额参与率 1%/5%/10% 情景，并输出行业、市值、个股、回撤和成本贡献。仍需在真实数据上扩展调仓频率、股票池和参数网格，并防止把多轮敏感性检验反复用于挑选最终参数。

LLM 辅助模块

LLM 事件模块的定位是辅助解释与事件标签结构化，不是直接生成交易指令。主线已合并离线标签客户端、prompt、schema、JSONL 缓存和人工抽查表；每条新标签保留原文、来源、发布时间、prompt/model 版本、原始 JSON、cache key 和创建时间。默认 rule-based dry-run，不调用外部 API；人工一致性低于阈值时事件因子不进入组合。

在研究报告中，LLM 模块更适合回答“为什么某些股票在某个窗口出现异常收益或风险”，而不是自动给出买卖建议。若后续接入公告、新闻或研报摘要，应明确文本发布时间、抓取时间、去重规则和可用时间，避免把盘后或未来发布的信息提前用于信号日。

结论、不足和改进方向

本项目已经形成一个可顺序复现的研究展示框架：Notebook 负责过程复现，reports/figures/ 保存图表和 CSV，Markdown 报告负责结论叙事，README 负责快速展示。当前最重要的价值不是样例

收益，而是把信号日、执行日、目标收益、成本、回撤、换手、行业暴露、订单成交审计和 LLM 风险放在同一个可验证流程中。

主要剩余风险包括：合成样例不能证明真实因子有效；真实历史成分、退市、复牌、新股和财务修订数据仍需验证；回测没有真实盘口深度和市场冲击校准；样本外、参数和容量框架虽已实现，但尚未在完整 PIT 数据上形成可信结论；LLM 标签工程具备抽查门槛，但仍缺合法真实文本源和已完成人工复核的标签集。

下一步建议按风险优先级推进。第一，接入真实数据并记录数据版本，重点补齐交易日历、指数成分、ST、停复牌、涨跌停和复权口径。第二，建立数据质量报告，检查主键、缺失、异常价格、成交额、覆盖率和时间对齐。第三，加入样本内外切分、滚动 IC、分年度表现、成本敏感性和参数敏感性。第四，完善回测执行层，加入成交额容量、延迟成交和订单失败后的持仓延续策略。第五，在 LLM 模块中加入 prompt 版本、人工抽查和标签质量评估。只有这些检查通过后，才适合讨论策略是否具备进一步研究价值。

免责声明

本报告仅用于量化研究流程、数据工程和系统开发展示。所有图表和指标基于合成样例数据或框架占位假设，不构成任何投资建议，不代表真实可获得收益，也不应作为交易决策依据。